



## 저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

공학 석사학위논문

# 디지털 영상을 이용한 YOLOv4 모델 기반 흑토마토 속도 분류

전남대학교 대학원  
지역·바이오시스템공학과

조 양 현

2021년 2월

# 디지털 영상을 이용한 YOLOv4 모델 기반 흑토마토 속도 분류

이 논문을 공학 석사학위 논문으로 제출함

전남대학교 대학원  
지역·바이오시스템공학과

조 양 현

지도교수 최 영 수

조양현의 공학 석사 학위논문을 인준함

심사위원장 유 수 남 (인)

심사위원 이 경 환 (인)

심사위원 최 영 수 (인)

2021년 2월

## 목 차

LIST OF TABLE .....	III
LIST OF FIGURES .....	VI
국문초록 .....	VIII
I. 서론 .....	1
II. 연구사 .....	3
III. 재료 및 방법 .....	5
1. 공시재료 .....	5
2. 영상 수집용 머신 비전 시스템 .....	8
가. 영상 수집 장치 .....	8
나. 영상 수집 .....	10
3. 딥러닝을 이용한 흑토마토 속도 분류 .....	12
가. 딥러닝 알고리즘 선정 .....	12
1) Two-Stage Detector .....	12
2) One-Stage Detector .....	12
3) YOLO(You Only Look Once) .....	13
나. 데이터 라벨링 및 데이터셋 구성 .....	15
다. YOLOv4 기반 흑토마토 속도 분류 .....	18
4. 흑토마토 속도 분류 성능평가 .....	20
IV. 결과 및 고찰 .....	21
1. 조도 조건의 영향 .....	21

가. 단일 조도 조건 YOLOv4 학습 모델의 속도 분류 성능 .....	21
나. 단일 조도 조건 YOLOv4 학습 모델의 조도 변화 적응성 분석 .....	25
다. 혼합 조도 조건 YOLOv4 학습 모델의 속도 분류 성능 .....	37
2. 학습 데이터셋 크기의 영향 .....	39
3. 데이터 학습량의 영향 .....	41
V. 요약 및 결론 .....	43
참고문헌 .....	45
Abstract .....	48

## LIST OF TABLES

Table 1. USDA tomato color classification chart .....	6
Table 2. Color chart to classify the ripening stage of black tomato in this study .....	7
Table 3. Specification of MILC camera .....	9
Table 4. Specification of illuminometer .....	10
Table 5. Examples of recommended levels of illumination(KS A 3011) .....	10
Table 6. Data sets for each 570 lx, 1,240 lx and 2,780 lx condition ....	16
Table 7. Data sets for all illuminance condition .....	17
Table 8. Specifications of the computer in this study .....	19
Table 9. Parameters of YOLOv4 set to classify the black tomato ripeness .....	19
Table 10. Classification result with 570 lx test set by YOLOv4 model trained under the same illuminance .....	22
Table 11. Classification performance with 570 lx test set by YOLOv4 model trained under the same illuminance .....	22
Table 12. Classification result with 1,240 lx test set by YOLOv4 model trained under the same illuminance .....	23

Table 13. Classification performance with 1,240 lx test set by YOLOv4 model trained under the same illuminance .....	23
Table 14. Classification result with 2,780 lx test set by YOLOv4 model trained under the same illuminance .....	24
Table 15. Classification performance with 2,780 lx test set by YOLOv4 model trained under the same illuminance .....	24
Table 16. Classification result with 1,240 lx test set by YOLOv4 model trained under the 570 lx .....	26
Table 17. Classification performance with 1,240 lx test set by YOLOv4 model trained under the 570 lx .....	26
Table 18. Classification result with 2,780 lx test set by YOLOv4 model trained under the 570 lx .....	27
Table 19. Classification performance with 2,780 lx test set by YOLOv4 model trained under the 570 lx .....	28
Table 20. Classification result with 2,780 lx test set by YOLOv4 model trained under the 1,240 lx .....	29
Table 21. Classification performance with 2,780 lx test set by YOLOv4 model trained under the 1,240 lx .....	29
Table 22. Classification result with 570 lx test set by YOLOv4 model trained under the 1,240 lx .....	30

Table 23. Classification performance with 570 lx test set by YOLOv4 model trained under the 1,240 lx .....	31
Table 24. Classification result with 1,240 lx test set by YOLOv4 model trained under the 2,780 lx .....	32
Table 25. Classification performance with 1,240 lx test set by YOLOv4 model trained under the 2,780 lx .....	32
Table 26. Classification result with 570 lx test set by YOLOv4 model trained under the 2,780 lx .....	33
Table 27. Classification performance with 570 lx test set by YOLOv4 model trained under the 2,780 lx .....	34
Table 28. Average classification performance of YOLOv4 models trained under each 570 lx, 1,240 lx, 2,780 lx for the different illuminance test set .....	36
Table 29. Classification result of YOLOv4 model trained under all illuminance conditions .....	37
Table 30. Classification performance of YOLOv4 model trained under all illuminance conditions .....	38
Table 31. Classification performance according to training set sizes ....	39
Table 32. Classification performance according to training steps .....	41



# LIST OF FIGURES

Figure 1. Black Change tomatoes growing in a greenhouse .....	5
Figure 2. Machine vision system for collecting black tomato images .....	8
Figure 3. Example of black tomato images classified by ripening stage	11
Figure 4. Progress of Two-Stage detector .....	12
Figure 5. Progress of One-Stage detector .....	13
Figure 6. Object detection method using YOLO .....	13
Figure 7. Intersection over Union .....	14
Figure 8. Image data labeling .....	15
Figure 9. Classification of black tomato ripeness based on YOLOv4 .....	18
Figure 10. Confusion matrix for evaluating classification performance ·	20
Figure 11. Sample images of the same black tomato under different illuminance .....	21
Figure 12. Comparison of classification accuracy of YOLOv4 model trained under the 570 lx for the different illuminance test set .....	28
Figure 13. Comparison of classification accuracy of YOLOv4 model trained under the 1,240 lx for the different illuminance test set .....	31

Figure 14. Comparison of classification accuracy of YOLOv4 model trained under the 2,780 lx for the different illuminance test set .....	34
Figure 15. Example of incorrect classification results for the same black tomato due to a YOLOv4 model trained by different illuminance.....	35
Figure 16. Comparison of average classification accuracy between the same illuminance test set and different illuminance test set as the training sett .....	36
Figure 17. Comparison of classification accuracy by training set size ....	40
Figure 18. Comparison of classification accuracy according to training steps .....	42

# 디지털 영상을 이용한 YOLOv4 모델 기반 흑토마토 속도 분류

조 양 현

전남대학교대학원 지역바이오시스템공학과

(지도교수 : 최영수)

(국문초록)

흑토마토는 암, 피부 노화, 각종 성인병 예방 등에 도움이 되는 Lycopene, Anthocyanin,  $\beta$ -carotene, Quercetin, Rutin과 같은 항산화 물질과 다양한 미네랄 성분 및 비타민이 다른 종의 토마토에 비해 다량 함유되어 있어 기능성 고품질 토마토로 주목받고 있다. 속도는 당도, 색상, 영양성분 등 흑토마토의 품질을 결정하는 중요 요소로서 유통과 소비 등을 고려한 정확한 분류를 통해 최적의 품질을 유지하고 수확 후 발생 가능한 손실을 최소화해야 한다.

이에 본 연구에서는 실시간의 흑토마토 속도 자동 선별시스템 개발을 위한 기초연구로서 최신 객체 탐지 딥러닝 모델인 YOLOv4를 이용해 흑토마토 속도 분류 모델을 개발하였다. 또한, 최소 데이터와 학습량으로 시간 효율적이고 실제 속도 분류 환경에서 높은 성능과 적응성을 나타내는 모델 개발을 위해 조도 조건, 학습 데이터셋 크기, 데이터 학습량에 따른 YOLOv4 학습 모델의 속도 분류 성능을 평가하였다.

딥러닝 학습 및 시험을 위한 흑토마토 영상 수집을 위하여 MILC 카메라, 조명 장치, 편광필터 등으로 구성된 영상 수집용 머신 비전 시스템을 구축하였으며, 여러 방향의 흑토마토 영상에 대한 속도를 동시에 분류하기 위하여 4단계의 속도 단계 설정 기준에 따라 분류한 ‘블랙체인지’ 품종 흑토마토 340개를 세 수준의 조도 570 lx, 1,240 lx, 2,780 lx에서 시료 1개당 상, 하, 좌, 우 4면을 촬영

한  $4,912 \times 3,264$  해상도, JPEG 형식의 영상 총 4,080장을 이용하였다.

조도 조건의 영향 분석 결과 세 수준의 조도에서 촬영한 영상을 각각 학습한 단일 조도 조건 YOLOv4 학습 모델에 대한 동일 조도 조건 시험 영상의 속도 분류 성능은 모두 99.00% 이상으로 나타났으나 다른 조도 조건 시험 영상에 대한 속도 분류 성능은 비교적 낮게 나타났다. 즉, 570 lx ~ 2,780 lx 범위에서 특정 조도의 영상만을 학습한 YOLOv4 모델은 해당 조도가 일정한 분류 환경에서는 조도의 세기와 상관없이 높은 분류 성능을 나타내지만, 조명의 노후화, 오염, 교체 등으로 인해 조도가 변화될 수 있는 실제 분류 환경에서는 적응성이 낮은 것으로 판단되었다. 세 수준의 조도에서 촬영한 흑토마토 영상을 함께 학습한 혼합 조도 조건 YOLOv4 학습 모델은 촬영 방향 및 조도 변화와 상관없이 100.00%의 높은 분류 성능을 나타내었다. 즉, 조도 변화에 따른 오분류 현상이 개선되었으며 단일 조도 조건 YOLOv4 모델보다 실제 분류 환경에 적응성이 높다고 판단되었다.

학습 데이터셋의 크기 및 학습량의 영향 분석 결과 혼합 조도 조건 YOLOv4 학습 모델 기준 1,632장 이상의 영상을 3,000번 이상 학습한 결과 95.00% 이상의 유의성 있는 높은 분류 성능을 나타내었다.

## I. 서론

토마토는 다양한 영양성분을 포함하고 있을 뿐 아니라 종류에 따라 생식용, 조리용, 가공용 등 활용도가 높아 매우 중요한 농산물로 인식되고 있으며 소비 품종과 용도가 점차 다양해지고 있다. 그 중, 흑토마토는 암, 피부 노화, 각종 성인병 예방 등에 도움이 되는 Lycopene, Anthocyanin,  $\beta$ -carotene, Quercetin, Rutin과 같은 항산화 물질과 다양한 미네랄 성분 및 비타민이 다른 종의 토마토에 비해 다량 함유되어 있어 기능성 고품질 토마토로 주목받고 있다.

흑토마토와 같은 과채류는 크기, 색상, 당도와 같은 품질 특성에 따라 상품 가치에 영향을 받는다. 2016년 농촌진흥청 조사에 따르면 토마토 구매 시 선택기준은 당도 26.8%, 색상 23.8%, 가격 14.2%, 품종 13.3%, 크기 9.3%, 모양 7.2%, 생산지 5.3%로 당도와 색상이 가장 중요한 것으로 나타났다(RDA, 2016). 흑토마토는 자색 및 검은색을 띠는 Phytochemical 성분인 Anthocyanin에 의해 미숙 단계에서 암녹색을 나타내다가 숙도 발달이 진행됨에 따라 녹색을 띠는 Chlorophyll이 파괴되어 감소하고 적색을 띠는 Lycopene이 합성되어 증가해 점차 암적색의 색상으로 변화된다(Borghesi 등, 2011; Klee 등, 2011). 또한, 과당과 포도당이 축적되어 당도가 증가하고 항산화 물질과 같은 기능성 성분이 증가한다(Gautier 등, 2008; Dumas 등, 2003; Radzevičius 등, 2009). 즉, 숙도는 당도 및 색상 등 주요 품질 특성 변화에 직접 관여하기 때문에 흑토마토의 품질을 결정하는 가장 중요한 요소라고 말할 수 있다.

숙도 발달은 축적된 탄수화물 등의 저장양분이 산화되는 과정인 호흡과 과실의 숙성 유도 및 촉진 관련 대사 작용을 주도하는 에틸렌에 의하여 진행된다. 과실의 호흡은 산소를 소모하고 이산화탄소를 발생시키며 주위의 온도, 산소, 이산화탄소, 에틸렌 등의 요인에 의해 영향을 받는다. 흑토마토는 호흡 급등형 과실로 성숙 및 숙도 발달에 따라 호흡량과 에틸렌 생성량이 급격히 증가한다. 숙도 발달이 완료된 이후에는 과실의 노화가 진행되어 세포의 생리적 기능을 상실하고 조직의 붕괴와 함께 품질이 급격히 떨어진다.

후숙 과일인 흑토마토는 미숙 상태에서 수확된 이후에도 숙도 발달이 지속되기 때문에 완숙 또는 완숙되기 전 여러 숙도의 과실이 함께 수확된다. 수확 후 분류, 저장 및 유통단계에서 다른 숙도의 흑토마토가 함께 혼합될 경우 과실 간

호흡량 및 에틸렌 생성량 차이로 인해 숙성 및 노화 속도가 가속화되어 산패 과실이 발생 또는 증가하는 등 품질 저하 문제가 발생할 수 있다. 따라서 소비자들이 흑토마토를 구매, 섭취하기 전까지 최적의 품질을 유지하고 수확 후 발생하는 손실을 최소화하기 위해 수확 시기, 유통 거리 및 과정, 활용용도 및 소비 등을 고려한 정확한 속도 분류가 필요하다.

흑토마토의 속도는 일반적으로 표면의 색상 분포 특성 및 비율을 기준으로 육안에 의해 비교 및 판단하거나 색차계와 같은 기기를 사용해 색을 측정하여 분류한다. 육안에 의한 주관적 평가 방법은 비교적 빠르고 간편하지만 많은 노동력이 소요되고 작업자에 따라 분류 결과가 달라질 수 있어 신뢰성이 낮다. 기기 분석에 의한 객관적 평가 방법은 비교적 신뢰성 있는 분류 결과를 얻을 수는 있으나 대량의 흑토마토를 빠르게 분류하기에는 어려운 단점이 있다.

이에 본 연구는 흑토마토 속도 자동 분류 시스템 개발을 위한 기초연구로 영상 수집용 머신 비전 시스템을 통해 획득한 흑토마토 영상과 최신 딥러닝 기술을 이용해 속도 단계별 흑토마토 분류 실험을 수행하였다. 또한, 최소의 데이터와 학습량으로 시간 효율적이면서 높은 분류 성능을 나타내고 실제 흑토마토 속도 분류 환경에 적응성이 높은 모델을 개발하기 위하여 조도 조건, 학습 데이터 셋 크기, 학습량에 따른 딥러닝 학습 모델의 분류 성능을 평가 및 분석하였다.

## II. 연구사

농업 분야에서는 농산물의 손실을 줄이고 부가가치를 높이기 위해 여러 품질 특성을 평가 및 분류하는 다양한 선별 기술이 이용되고 있다. 그 중, 토마토, 망고, 바나나와 같은 후숙 과일은 저장 및 유통 과정에서 숙도 발달에 따라 품질 변화에 직접적인 영향을 받기 때문에 숙도와 관련한 품질 특성을 평가 및 분류할 수 있는 선별 기술이 필요하다.

이에 최근에는 숙도 선별 자동화를 위해 영상처리, 머신 비전, 머신 러닝 등을 이용한 연구가 진행되고 있다.

Arakeri(2016) 등은 다층 신경망 기반의 컴퓨터 비전 기술을 이용한 토마토 자동 등급 평가 방법을 제시하였다. 해당 시스템은 토마토를 적정 라벨의 상자로 이송하는 하드웨어와 결함 탐지 및 숙도 분석을 위한 소프트웨어로 구성하였으며 이를 위해 총 520장의 토마토 영상을 수집 및 RGB 분석에 이용하였다. 제안된 이미지 처리 방법은 토마토의 결함을 100.00%의 정확도로 탐지 및 분류하였고, 미숙과와 성숙과의 구분을 96.47%의 정확도로 판별 가능함을 보였다. 그러나 등급 평가 기계의 용량은 300 fruits/hr로 제한적이었고 반사 현상이 발생한 토마토 영상에 대해서는 효과적으로 작동하지 않아 추후 실용화를 위해서는 속도와 정확도 측면의 추가 개선이 필요하다고 보았다.

Arjenaki(2013) 등은 토마토의 모양(장방형 및 원형), 크기(소형 및 대형), 숙도(색상) 및 결함을 평가 및 분류하기 위해 CCD 카메라, 마이크로 컨트롤러, IR 센서, LED 램프 등으로 구성된 머신 비전 기반 분류 시스템을 개발하였다. 영상은 Visual Basic 2008로 개발한 알고리즘을 사용해 RGB를 HSI로 변환, 이진화로 배경을 분리 및 영역 탐지 후 분석되었다. 총 210장의 토마토 영상에 대한 제안된 분류 시스템의 성능평가 결과 결함 탐지, 모양 및 크기 알고리즘, 전체 시스템의 정확도는 각각 84.4%, 90.9%, 94.5%, 90.0%로 측정되었으며 시스템 분류 성능은 1줄당 2,517 tomatoes/h로 추정되었다고 주장하였다.

Bejo(2014) 등은 Keyence 머신 비전 시스템을 사용하여 Chokanan 품종 망고의 당도와 RGB, HSB 색상 공간의 평균 픽셀값과의 관계를 분석하였다. 분석 결과 색조가 가장 높은 상관관계수(-0.916)를 가질 뿐만 아니라 다른 색상 성분과 비교해 당도 수준에서 표준 편차가 가장 낮다고 판단하였으며 레벨1과 레벨2에

서 100%, 레벨3에서 87%의 정확도로 당도를 판단할 수 있었다고 주장하였다.

El-Bendary(2015) 등은 속도 단계별 토마토의 색상 특징 추출 및 분류를 위해 SVM 및 LDA 알고리즘과 함께 PCA를 이용하였다. 훈련 및 테스트 데이터 세트에 사용된 총 250개의 영상에 대한 실험결과 제안된 방법의 속도 분류 정확도는 OAO 다중 클래스 SVM 알고리즘 사용방법이 90.80%, OAA 사용방법이 84.80%, 선형 커널 기능이 있는 다중 클래스 SVM 알고리즘 및 LDA 알고리즘 사용방법이 84.00%를 보였다고 주장하였다.

Hasan(2017) 등은 분류 트리를 기반으로 하는 FIS 시스템을 사용하여 구아바의 속도 추정 방법을 제안하였으며 200개의 구아바 영상에 대해 테스트를 진행한 결과 93.4%를 얻었다고 주장하였다. 이러한 결과는 Naive Bayesian 네트워크를 이용한 방법이 92.1%, MultiSVM 시스템을 이용한 방법이 84.2% 정확도를 달성한 것과 비교해 개선된 성능을 얻었음을 보였다.

Sanaeifar(2016) 등은 바나나의 색상을 RGB,  $L^* a^* b^*$ 로 평가하기 위한 컴퓨터 비전 시스템을 구현하였으며 품질 지수의 정량적 예측을 위해 유통기한 동안 바나나의 색상 특성 변화와 HSV를 사용하였다. RBF는 SVR의 커널 함수로 적용되었으며, 실험결과 ANN을 사용해 얻은 결과보다 예측 정확도가 향상되었다고 주장하였다.

Wan(2018) 등은 수집한 토마토의 RGB 영상에 노이즈 평활화 및 객체 컨투어 추출 과정을 수행한 후 HSI 모델로 변환해 색상의 특징을 추출하였으며 이를 기반으로 3단계의 속도를 99.31%의 정확도로 분류하였다고 주장하였다.

Zhang(2018) 등은 개발된 이미지 처리 기술을 기반으로 분할된 토마토 영상에서 추출한 RGB, HSI, FCA 등의 색상 특성과 BPNN을 기반으로 Roma와 Pear 품종 토마토를 3단계의 속도로 분류하였다. 토마토 영상의 H값을 추출하여 속도를 분류하는 방법의 정확도가 99.31%로 가장 우수했다고 주장하였다.

고광은(2018) 등은 CNN 기반의 single stage 객체 탐지 딥러닝 모델을 활용한 실시간 속도 분류 시스템을 활용하여 토마토를 6단계의 속도로 분류하였다. 모델의 효율적인 학습 및 테스트 성능 향상을 위해 자체 제작한 카메라 시스템을 사용해 4,182장의 토마토 영상을 수집하였으며 속도 분류 수행 결과 정확도는 91.3%, 분류 속도는 최대 97 fps로 실시간 분류가 가능함을 확인하였다.



### III. 재료 및 방법

#### 1. 공시재료

본 연구에 사용된 흑토마토는 광주광역시 광산구 동곡동에서 하우스 재배된 블랙체인지(Black Change) 품종을 이용하였다. 블랙체인지는 복합 내병성으로 재배 안정성이 우수하고 일반 완숙 토마토에 비해 기능성 성분인 Lycopene이 1.4배,  $\beta$ -carotene이 2배, Quercetin이 11배, Rutin이 20배 이상 함유된 국산 품종 흑토마토이다.



Figure 1. Black Change tomatoes growing in a greenhouse

토마토의 숙도는 일반적으로 표 1과 같이 착색의 정도에 따라 6단계로 정의한 USDA 토마토 컬러 분류 차트를 기준으로 판단하며, 이는 많은 연구에서도 활용되고 있다(최규홍 등, 1999; 김대용 등, 2009; 고광은 등, 2018). 이에 실험 당일 동곡농협 농산물 선별장에 입고된 블랙체인지 흑토마토를 USDA 차트의 색상 분포량을 참고하여 새롭게 설정한 흑토마토 숙도 단계 분류 기준에 따라 선별 전문가의 자문을 받아 4단계로 분류하였다. 흑토마토 숙도 단계 분류 기준은 표 2에 나타낸 바와 같으며 암녹색의 흑토마토 표면에 발현된 황색 및 적색, 암적색의 분포량이 10% 이하일 경우 1단계, 10%에서 50% 사이일 경우 2단계, 50%에서 90% 사이일 경우 3단계, 90% 이상일 경우 4단계로 설정하였다. 분류된 흑

토마토는 후숙에 의한 색상 변화를 방지하기 위하여 냉장 탐차로 낮은 온도 상태를 유지해 이송했으며 각 숙도 단계별로 1단계 40개, 2단계 ~ 4단계 각각 100개씩 총 340개를 실험에 이용하였다.

Table 1. USDA tomato color classification chart







Ripening Stage	Description
 Stage 1 / Green	The surface of the tomato is completely green in color. The shade of green may vary from light to dark
 Stage 2 / Breakers	There is a definite break in color from green to tannish-yellow, pink or red on not more than 10% of the surface
 Stage 3 / Turning	More than 10%, but not more than 30%, of the surface, in the aggregate, shows a definite change in color from green to tannish-yellow, pink, red, or a combination thereof
 Stage 4 / Pink	More than 30%, but not more than 60%, of the surface, in the aggregate, shows pink or red in color
 Stage 5 / Light Red	More than 60% of the surface, in the aggregate, shows pinkish-red or red, provided that not more than 90% of the surface is red
 Stage 6 / Red	More than 90% of the surface, in the aggregate, is red


Table 2. Color chart to classify the ripening stage of black tomato in this study

Ripening Stage	Description
Stage 1	Not more than 10% of the dark green surface, in the aggregate, shows orange, brown or red in color
Stage 2	More than 10%, but not more than 50%, of the surface, in the aggregate, shows orange, brown or red in color
Stage 3	More than 50%, but not more than 90%, of the surface, in the aggregate, shows brown, red or dark red in color
Stage 4	More than 90% of the surface, in the aggregate, is dark red

## 2. 영상 수집용 머신 비전 시스템

### 가. 영상 수집 장치

흑토마토 속도 분류를 위한 디지털 영상을 수집하기 위하여 그림 2와 같이 MILC 카메라, 조명장치, 편광필터 등으로 구성된 영상 수집 장치를 구축하였다.



(a) Schematic diagram of the system




(b) View of the system

Figure 2. Machine vision system for collecting black tomato images

MILC 카메라(Mirrorless Interchangeable Lens Camera)는 DSLR 카메라에서 미러와 광학식 뷰파인더를 전자식 시스템으로 간소화한 형태의 렌즈 교환식 카메라이다. 본 연구의 영상 수집 장치에는 표 3에 나타난 바와 같이 약 1,610만 화소의 유효 화소를 가진 APS-C 타입( $23.5\text{ mm} \times 15.6\text{ mm}$ )의 CMOS 센서가 탑재되어 최대  $4,912 \times 3,264$  해상도의 영상을 RAW 또는 JPEG 파일형식으로 저장할 수 있는 Sony NEX-5R을 사용하였다. 일정한 촬영 조건에서 영상을 수집하기 위해 카메라와 시료 간의 거리는 50 cm로 고정하였다.

Table 3. Specification of MILC camera

Figure	Index	Specification
	Model	Sony NEX-5R
	Sensor Type	CMOS
	Effective Pixels	16 megapixels
	Max Resolution	$4,912 \times 3,264$
	Image File Format	JPEG, RAW

조명장치는 흑토마토 표면에 빛이 고르게 조사되도록 LED 램프를 상단부 좌우에 각각  $45^\circ$ 의 각도로 설치하였으며, 시료와의 거리(L)를 조절해 촬영 면에서의 조도를 조절할 수 있도록 하였다. 흑토마토의 매끄러운 표면은 반사율이 높아 영상 촬영 시 조명에 의한 빛 반사로 인해 주변보다 비정상적으로 밝게 표현되는 화소 포화 현상이 발생하여 속도 분류 기준인 색상 정보의 질을 떨어뜨릴 수 있다. 김대용(2010) 등은 빛을 산란시킬 수 있는 영상처리 챔버를 제작하여 방울토마토 표면의 반사 현상을 줄이고자 하였다. 본 연구에서는 빛의 굴절률을 변화시켜 반사광을 차단 또는 제거하는데 사용하는 편광필터를 카메라 렌즈와 조명장치 주변에 부착하여 조명장치에 의한 흑토마토 표면의 반사 현상을 최소화하였다.

## 나. 영상 수집

본 연구에서는 딥러닝 학습 시 조명장치의 조도 조건이 속도 분류 성능에 주는 영향을 분석하고자 하였다. 이에 시료와 조명장치 사이의 거리를 조절한 후 조도계를 사용해 촬영 면의 조도를 측정하였으며 표 5에 나타낸 KS 조도 기준 예시(KS A 3011)를 참고해 570 lx, 1,240 lx, 2,780 lx 총 3가지 수준의 조도를 선정하였다.

Table 4. Specification of illuminometer


Figure	Index	Specification
	Model	ET-952
	Measuring Range	0~400k Lux, 0~40k Fc
	Operating Conditions	-20~60℃; < 90% RH
	Storage Conditions	-20~60℃; < 75% RH
	Accuracy	±3% rdg±0.5%f.s.( < 10,000 Lux) ±4% rdg±10dgts.( > 10,000 Lux)
	Sampling Rate	2 times / second
	Spectral Response	CIE photopic (CIE human eye response curve)
	Spectral Accuracy	CIE V λ function(f1'≤6%, f2'≤2%)

Table 5. Examples of recommended levels of illumination(KS A 3011)

Activity	Light level* [lx]
Classification of Tomato	300 – 400 – 600
Color Classification	600 – 1,000 – 1,500
Close Examination	1,500 – 2,000 – 3,000

\* min. – standard – max.

실제 속도 분류작업 수행 시에는 다양한 방향의 흑토마토 영상이 입력될 수 있다. 이때 흑토마토 과육의 꼭지와 배 영역에서 변화하는 색의 분포 특성이 일정하지 않기 때문에, 특정 방향 영상의 색 비율만을 고려할 경우 속도 판별이 정확하게 이루어지지 않을 수 있다. 이에 여러 방향의 흑토마토 영상에 대한 속도를 동시에 분류하기 위하여 그림 3과 같이 세 수준의 조도에서 속도 단계별 흑토마토 340개에 대해 한 개체당 상, 하, 좌, 우 4면을 촬영해  $4,912 \times 3,264$  해상도, JPEG 형식의 영상 총 4,080장을 수집하였다.

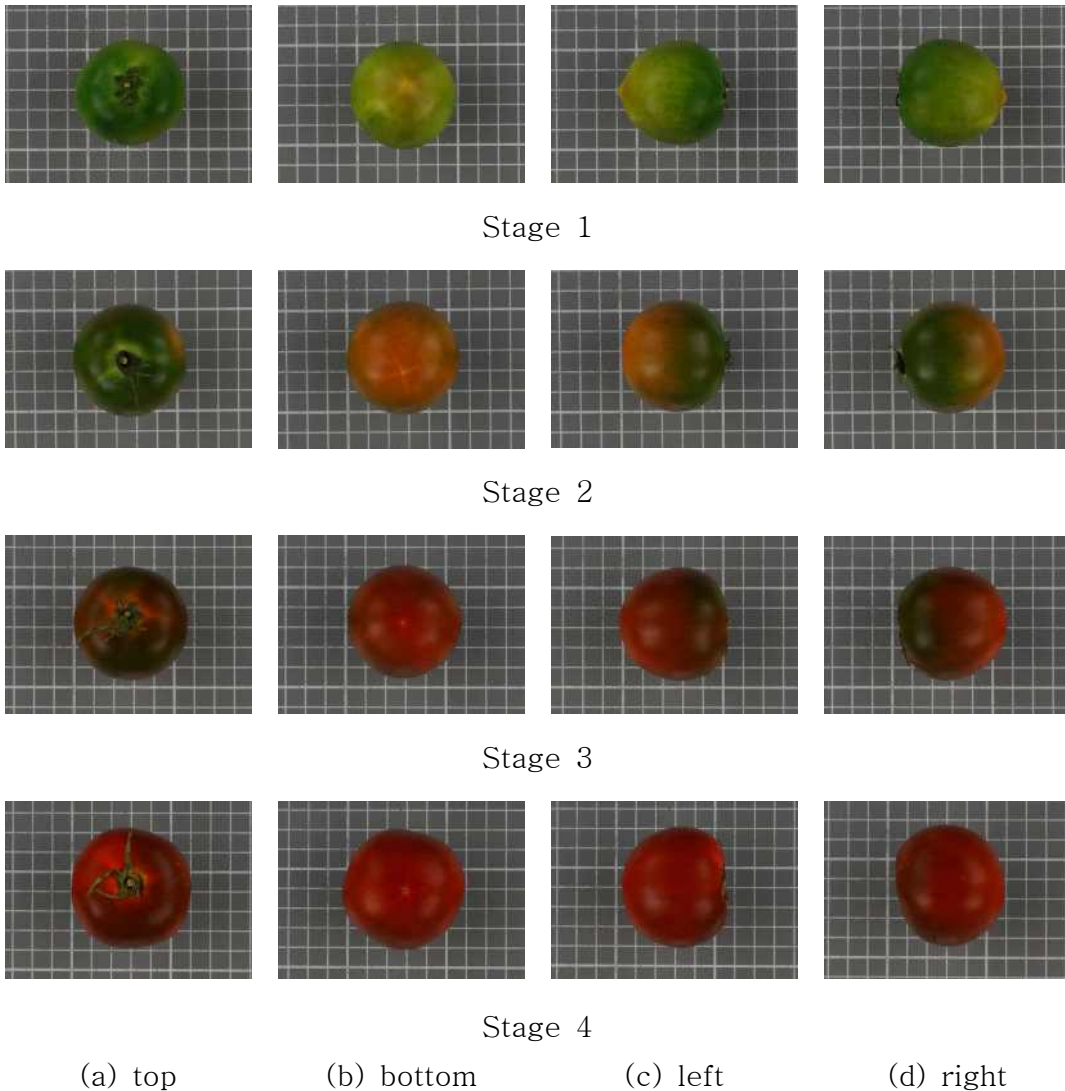


Figure 3. Example of black tomato images classified by ripening stage



### 3. 딥러닝을 이용한 흑토마토 속도 분류

#### 가. 딥러닝 모델 선정

실제 속도 분류작업 수행 시에는 한 영상에 여러 개의 흑토마토가 포함될 수 있다. 따라서 경계 상자(Bounding Box)를 통해 객체의 위치 정보를 나타내는 Localization 문제와 여러 객체를 분류하는 Classification 문제를 동시에 파악할 수 있는 CNN 기반의 객체 탐지(Object Detection) 모델을 사용하여 입력 영상에 존재하는 흑토마토를 탐지하고 속도 단계를 예측하고자 하였다. 딥러닝을 이용한 객체 탐지는 크게 Two-stage Detector와 One-Stage Detector로 나눌 수 있으며 각각 다음과 같은 특징을 가지고 있다.

##### 1) Two-Stage Detector

Two-Stage Detector는 Localization 문제와 Classification 문제를 순차적으로 수행하여 결과를 얻는 방법으로 그림 4와 같이 나타낼 수 있다. 일반적으로 One-Stage Detector보다 추론 속도는 느리지만, 정확도가 비교적 높다는 장점이 있다. 대표적인 알고리즘으로는 R-CNN, Fast R-CNN, Faster R-CNN, Mask R-CNN과 같은 R-CNN 계열 모델 등이 있다.




Figure 4. Progress of Two-Stage detector

##### 2) One-Stage detector

One-Stage Detector는 Localization 문제와 Classification 문제를 동시에 수행하여 결과를 얻는 방법으로 그림 5와 같이 나타낼 수 있다. 일반적으로 Two-Stage Detector보다 정확도는 비교적 낮을 수 있지만, 추론 속도가 빨라 실시간 사용이 가능하다는 장점이 있다. 대표적인 알고리즘으로는 YOLO, SSD 계열 모델 등이 있다.






Figure 5. Progress of One-Stage detector

### 3) YOLO(You Only Look Once)

YOLO(You Only Look Once)는 Redmon(2016) 등에 의하여 제안된 One-Stage detector 알고리즘으로 영상 전체에 대해서 하나의 합성곱 신경망을 통해 경계 상자와 클래스 확률(Class Probability)을 예측한다. YOLO의 객체 탐지 원리는 그림 6에 나타난 바와 같다.

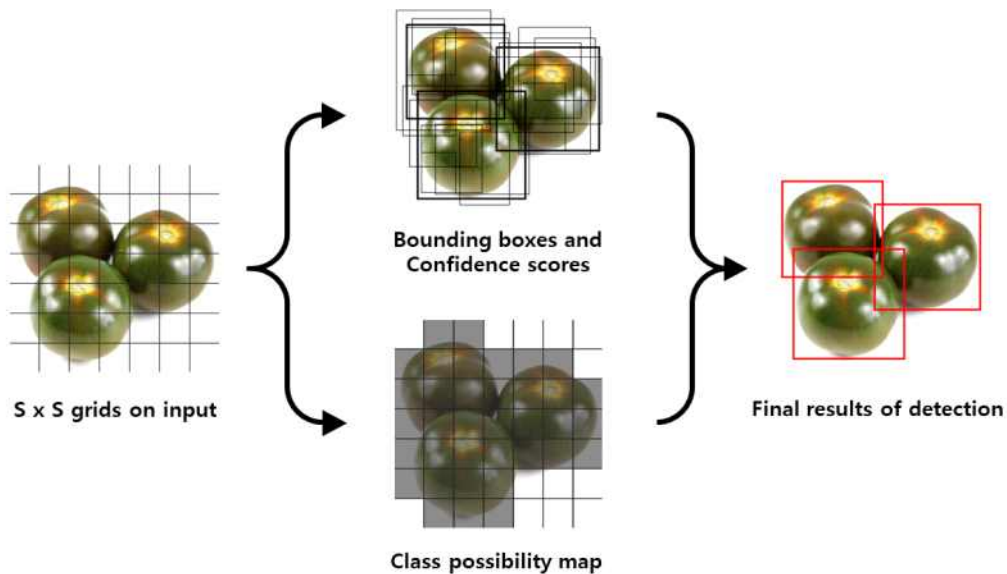


Figure 6. Object detection method using YOLO

각 입력 이미지를  $S \times S$  그리드로 나누며 그리드 셀 중 객체의 중심과 가장 가까운 셀이 객체를 탐지하는 역할을 한다. 각 그리드 셀은 B개의 경계 상자와 각 경계 상자에 해당하는 신뢰도 점수(Confidence Score)로 표현된다.

신뢰도 점수는 식 1과 같이 정의되며 객체가 경계 상자 영역 안에 포함되어 있을 확률이 얼마나 되는지와 객체의 클래스를 잘 예측하였는지를 나타낸다.

$$Confience\ Score = p(Object) \times IoU_{pred}^{truth} \quad (1)$$

위 식에서  $p(Object)$ 는 경계 상자의 객체 포함 확률로 그리드 셀 안에 객체가 존재할 경우  $p(Object) = 1$ , 존재하지 않을 경우  $p(Object) = 0$ 의 값을 갖는다.  $IoU$ 는 Intersection over Union의 약자로 식 2와 같이 계산되며 그림 7과 같이 학습 데이터의 경계 상자 즉, 실제값(Ground Truth)과 예측한 경계 상자(Prediction Box)가 일치하는 정도를 나타낸다.

$$IoU = \frac{Prediction\ Box \cap Ground\ Truth}{Prediction\ Box \cup Ground\ Truth} \quad (2)$$




Figure 7. Intersection over Union

결과적으로 객체가 있을 만한 위치에 여러 개의 예측 경계 상자가 탐지되며 NMS(Non Maximum Suppression) 알고리즘을 적용하여 중복된 경계 상자를 제거해 하나의 최적 경계 상자를 선정한다.

## 나. 데이터 라벨링 및 데이터셋 구성

흑토마토 속도 분류 작업을 위해 Yolo\_mark 프로그램을 이용하여 영상 안의 흑토마토 객체에 그림 8과 같이 경계 상자를 수작업으로 마킹해 Ground Truth를 라벨링하였다. 마킹한 경계 상자에 대한 정보는 다음과 같으며 txt 파일 형식으로 저장하였다.

$$[Class\ ID, X, Y, Width, Height] \quad (3)$$

*Class ID*는 경계 상자로 지정한 흑토마토 개체의 클래스 즉, 속도 단계 정보를 나타내며, (*X, Y*)는 경계 상자의 중심 좌표, (*Width, Height*)는 각각 경계 상자의 너비와 높이를 나타낸다.



(a) Labeled ground-truth image      (b) Class ID and coordinate information

Figure 8. Image data labeling

각 570 lx, 1,240 lx, 2,780 lx 조건의 데이터셋은 표 6과 같이 속도 단계별로 촬영 방향을 고려하여 라벨링 작업을 수행한 각 조도별 영상 총 1,360장에 대해 임의로 선택한 80%의 영상 1,088장을 학습용 데이터로, 학습시키지 않은 나머지 20%의 영상 272장을 시험용 데이터로 구성하였다. 또한, 조도 변화 적응성 분석을 위한 세 수준의 조도 혼합 조건 데이터셋은 표 7과 같이 조도, 속도 단계, 촬영 방향을 고려 총 4,080장의 영상에 대해 임의로 선택한 80%의 영상 3,264장을 학습용 데이터로, 학습시키지 않은 나머지 20%의 영상 816장을 시험용 데이터로 구성하였다.

Table 6. Data sets for each 570 lx, 1,240 lx and 2,780 lx condition

Class	Direction	The Number of Images		
		Training Set	Test Set	Total
Stage 1	Top	32	8	40
	Bottom	32	8	40
	Left	32	8	40
	Right	32	8	40
Stage 2	Top	80	20	100
	Bottom	80	20	100
	Left	80	20	100
	Right	80	20	100
Stage 3	Top	80	20	100
	Bottom	80	20	100
	Left	80	20	100
	Right	80	20	100
Stage 4	Top	80	20	100
	Bottom	80	20	100
	Left	80	20	100
	Right	80	20	100
Total		1,088	272	1,360

Table 7. Data sets for all illuminance condition

Illuminance	Class	The Number of Images		
		Training Set	Test Set	Total
570 lx 1,240 lx 2,780 lx	Stage 1	384	96	480
	Stage 2	960	240	1,200
	Stage 3	960	240	1,200
	Stage 4	960	240	1,200
Total		3,264	816	4,080

#### 다. YOLOv4 기반 흑토마토 속도 분류

디지털 영상을 이용한 흑토마토 속도 분류 딥러닝 모델 개발을 위하여 Bochkovsky(2020) 등에 의해 제안된 최신 One-Stage detector인 YOLOv4를 활용하였다. YOLOv4는 그림 9와 같이 백본(Backbone)은 CSPNet 기반의 CSP-Darknet53, 헤드(Head)는 YOLOv3, 넥(Neck)은 SPP와 PANet으로 구성되었다. 백본은 입력 영상을 feature map으로 변형시켜주고, 헤드는 백본에서 추출한 feature map의 localization 문제를 수행하는 부분으로 클래스 확률 예측 및 경계 상자 작업을 수행한다. 넥(Neck)은 백본과 헤드를 연결하는 부분으로 feature map을 정제하고 재구성한다.

YOLOv4는 단일 GPU로 학습과 테스트, 모델 배포가 가능해 실용적이다. 또한, MS COCO 데이터 집합에서 43.5%(65.7% AP50)의 평균 정밀도(AP), Tesla V100에서 65 fps의 실시간 속도를 달성하였으며 YOLOv3에 비해 평균 정밀도는 10%, 임베디드 보드 처리속도(FPS)는 12% 증가하였다(Bochkovsky, 2020).

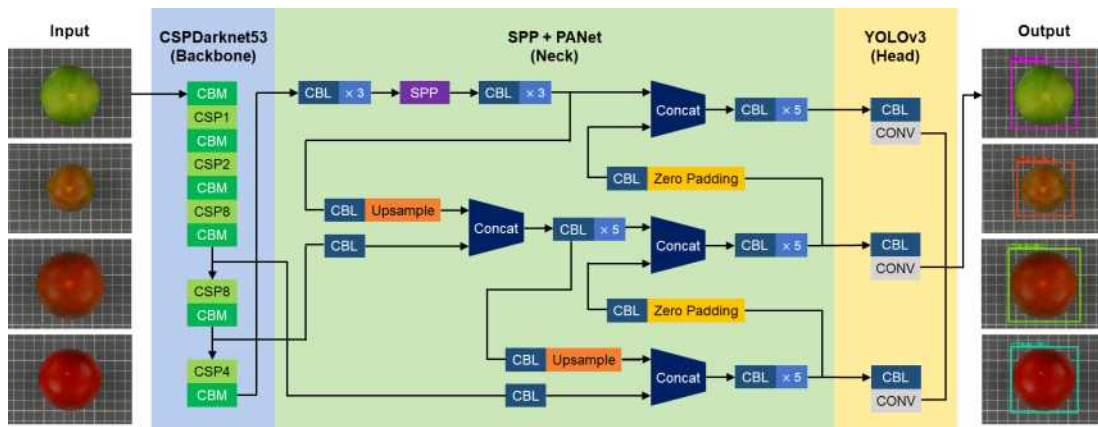


Figure 9. Classification of black tomato ripeness based on YOLOv4

YOLOv4 모델 기반 흑토마토 속도 분류를 위해 하드웨어 환경은 표 8에 나타난 바와 5.2GHz Intel(R) Core(TM) i9-10900F와 함께 32GB RAM, 8GB NVIDIA Geforce(R) RTX 2070 Super GPU 등으로 구축하였으며 Ubuntu 18.04 LTS 64bit 상에서 CUDA 10.0을 활용하였다.

Table 8. Specifications of the computer in this study

Component	Specification
CPU	Intel(R) Core(TM) i9-10900F @ 5.2GHz
RAM	DDR4-2666 32GB
GPU	NVIDIA Gefore(R) RTX 2070 Super(TM) @ 8GB
OS	Ubuntu 18.04 LTS 64bit

YOLOv4의 흑토마토 탐지 및 속도 분류 성능을 높이고 학습 도중의 오류를 줄이기 위해서는 파라미터를 적절히 조절해야 한다. 이에 표 9에 나타낸 바와 같이 GPU 메모리를 고려하여 입력 영상 크기는  $608 \times 608$  해상도, batch size는 64, subdivisions(mini-batch)는 32, 학습 횟수는 8,000번으로 설정하였다.

Table 9. Parameters of YOLOv4 set to classify the black tomato ripeness

Parameters	Value
Image Size	$608 \times 608$
Batch	64
Subdivisions	32
Learning Rate	0.0013
Classes	4
Training Step	8,000

#### 4. 흑토마토 속도 분류 성능평가

본 연구에서는 YOLOv4 기반 흑토마토 속도 분류 모델의 성능을 평가하기 위하여 식 (4) ~ 식 (7)에 따라 Precision, Recall, F1 Score, Accuracy를 계산하였다. Precision은 특정 속도 단계의 흑토마토라 예측한 것 중에서 실제로 해당 속도 단계인 것의 비율, Recall은 실제 특정 속도 단계인 흑토마토에 대해 해당 속도 단계라 예측한 것의 비율을 의미한다. F1 Score는 모델의 성능을 하나의 수치로 표현하기 위해 사용하는 지표로 Precision과 Recall의 조화평균이며, Accuracy는 전체 예측에서 옳게 예측한 것의 비율을 의미한다.

$$Precision = \frac{TP}{TP + FP} \quad (4)$$

$$Recall = \frac{TP}{TP + FN} \quad (5)$$

$$F1\,Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (6)$$

$$Accuracy = \frac{TP + TN}{TP + FN + FP + TN} \quad (7)$$

위 식에서 TP, TN, FP, FN의 정의는 그림 10에 나타낸 바와 같으며 각각 True Positive, True Negative, False Positive, False Negative를 의미한다.

		<i>Predicted Class</i>	
		<i>Positive</i>	<i>Negative</i>
<i>Actual Class</i>	<i>Positive</i>	True Positive (TP)	True Negative (TN)
	<i>Negative</i>	False Positive (FP)	False Negative (FN)

Figure 10. Confusion matrix for evaluating classification performance



#### IV. 결과 및 고찰

##### 1. 조도 조건의 영향

그림 11은 동일한 흑토마토를 세 수준의 조도에서 촬영한 영상의 예시로 조도에 따라 흑토마토 표면의 색온도 및 반사 현상에 차이가 발생하는 모습을 확인할 수 있었다. 즉, 영상 수집 및 분류작업 시 조명장치의 조도는 흑토마토의 속도를 판별하는 기준인 색상에 영향을 주기 때문에 속도를 정확히 분류하는데 중요한 요소라 생각되었으며 이에 영상의 조도 조건에 따른 YOLOv4 모델의 분류 성능을 분석하였다.




Figure 11. Sample images of the same black tomato under different illuminance

##### 가. 단일 조도 조건 YOLOv4 학습 모델의 속도 분류 성능

조도의 세기가 흑토마토 속도를 분류하는데 주는 영향을 분석하기 위해 570 lx, 1,240 lx, 2,780 lx 세 수준의 조도에서 촬영한 흑토마토 영상을 이용하여 조도에 따른 YOLOv4 학습 모델의 속도 분류 성능을 비교하였다. 각 조도별 YOLOv4 학습 모델은 표 6의 데이터 구성에 따라 해당 조도에서 흑토마토의 상, 하, 좌, 우 4면을 촬영한 임의의 1,088장의 영상을 사용하여 학습한 후 각각 같은 조도의 시험 영상 272장에 대하여 속도 분류 성능을 평가하였다.

선정한 세 수준의 조도 중 가장 낮은 570 lx에서 촬영한 흑토마토 영상을 학습한 YOLOv4 모델의 속도 분류 수행 결과는 표 10과 같으며 272장의 시험 영상 중 오직 1개의 영상만을 오분류한 것으로 나타났다.

Table 10. Classification result with 570 lx test set by YOLOv4 model trained under the same illuminance

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	32				32
Stage 2		79	1		80
Stage 3			80		80
Stage 4				80	80
Total	32	79	81	80	272

표 10의 결과를 기반으로 속도 분류 성능을 평가한 결과, 표 11에 나타낸 바와 같이 평균 Precision, Recall, F1 Score는 각각 99.69%, Accuracy는 99.63%로 측정되었다.

Table 11. Classification performance with 570 lx test set by YOLOv4 model trained under the same illuminance

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
570 lx	570 lx	Precision	99.69
		Recall	99.69
		F1 Score	99.69
		Accuracy	99.63

선정한 세 수준의 조도 조건 중 중간 정도의 밝기인 1,240 lx에서 촬영한 흑 토마토 영상을 학습한 YOLOv4 모델의 속도 분류 수행 결과는 표 12와 같으며 272장의 시험 영상에 대하여 모두 옳게 분류한 것으로 나타났다.

Table 12. Classification result with 1,240 lx test set by YOLOv4 model trained under the same illuminance

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	32				32
Stage 2		80			80
Stage 3			80		80
Stage 4				80	80
Total	32	80	80	80	272

표 12의 결과를 기반으로 흑토마토 속도 분류 성능을 평가한 결과, 표 13에 나타낸 바와 같이 평균 Precision, Recall, F1 Score, Accuracy 모두 각각 100.00%로 측정되었다.

Table 13. Classification performance with 1,240 lx test set by YOLOv4 model trained under the same illuminance

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
1,240 lx	1,240 lx	Precision	100.00
		Recall	100.00
		F1 Score	100.00
		Accuracy	100.00

선정한 세 수준의 조도 조건 중 가장 높은 2,780 lx에서 촬영한 흑토마토 영상 학습한 YOLOv4 모델의 속도 분류 수행 결과는 표 14과 같으며 272장의 시험 영상에 대하여 모두 옳게 분류한 것으로 나타났다.

Table 14. Classification result with 2,780 lx test set by YOLOv4 model trained under the same illuminance

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	32				32
Stage 2		80			80
Stage 3			80		80
Stage 4				80	80
Total	32	80	80	80	272

표 14의 결과를 기반으로 흑토마토 속도 분류 성능을 평가한 결과, 1,240 lx 조건 영상의 학습 결과와 마찬가지로 표 15에 나타낸 바와 같이 평균 Precision, Recall, F1 Score, Accuracy 모두 각각 100.00%로 측정되었다.

Table 15. Classification performance with 2,780 lx test set by YOLOv4 model trained under the same illuminance

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
2,780 lx	2,780 lx	Precision	100.00
		Recall	100.00
		F1 Score	100.00
		Accuracy	100.00

결과적으로 조도별 YOLOv4 학습 모델을 이용하여 각각 동일한 조도의 시험 영상에 대해 속도 분류 성능을 평가한 결과 570 lx에서 99.63%, 1,240 lx와 2,780 lx에서 각각 100.00%의 매우 높은 분류 정확도를 나타내었다. 즉, 570 lx ~ 2,780 lx 범위에서 조도의 세기는 흑토마토 속도 분류 성능에 큰 영향을 주지 않은 것으로 판단되었다. 또한, 특정 조도의 영상만을 학습한 YOLOv4 모델은 조도 세기와 상관없이 동일한 조도 조건이 일정한 분류 환경에서 여러 시점의 흑토마토에 대해 속도 단계를 높은 성능으로 잘 분류할 수 있음을 확인하였다.

#### 나. 단일 조도 조건 YOLOv4 학습 모델의 조도 변화 적응성 분석

실제 흑토마토 속도 분류를 수행하는 작업 환경의 조도는 조명기구의 노후화, 오염, 교체 등으로 인하여 변화될 수 있다. 이에 조도가 일정하지 않거나 변화될 수 있는 분류 환경에서 각 조도별 YOLOv4 학습 모델의 적응성을 테스트하기 위해 학습용 데이터의 조도와 다른 두 가지 조도의 시험 영상 각 272장에 대하여 속도 분류 성능을 평가하였다.

570 lx 조건 YOLOv4 학습 모델에 대한 1,240 lx 시험 영상의 속도 분류 수행 결과는 표 16과 같으며 272장의 영상 중 4개의 영상에 대해 실제 속도 단계보다 한 단계 높은 속도 단계로 오분류한 것으로 나타났다.

Table 16. Classification result with 1,240 lx test set by YOLOv4 model trained under the 570 lx

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	32				32
Stage 2		78	2		80
Stage 3			78	2	80
Stage 4				80	80
Total	32	78	80	82	272

표 16의 결과를 기반으로 흑토마토 속도 분류 성능을 평가한 결과, 표 17에 나타낸 바와 같이 평균 Precision은 98.77%, Recall은 98.75%, F1 Score는 98.76%, Accuracy는 98.53%로 측정되었으며 동일 조도 조건 시험 영상에 대한 속도 분류 결과에 비해 비교적 낮은 성능을 나타내었다.

Table 17. Classification performance with 1,240 lx test set by YOLOv4 model trained under the 570 lx

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
570 lx (1,088 images)	1,240 lx (272 images)	Precision	98.77
		Recall	98.75
		F1 Score	98.76
		Accuracy	98.53

570lx 조건 YOLOv4 학습 모델에 대한 2,780lx 시험 영상의 속도 분류 수행 결과는 표 18과 같다. 272장의 영상 중 33개의 영상에 대해 실제 속도 단계보다 한 단계 높거나 낮은 속도 단계로 오분류하였고, 2개의 영상에 대해 두 단계 높은 속도 단계로 오분류한 것으로 나타났다.

Table 18. Classification result with 2,780 lx test set by YOLOv4 model trained under the 570 lx

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	32				32
Stage 2	15	57	6	2	80
Stage 3		7	70	3	80
Stage 4			2	78	80
Total	47	64	78	83	272

표 18의 결과를 기반으로 흑토마토 속도 분류 성능을 평가한 결과, 표 19에 나타난 바와 같이 평균 Precision은 85.22%, Recall은 89.06%, F1 Score는 87.10%, Accuracy는 87.13%로 측정되었으며 마찬가지로 동일 조도 조건 시험 영상의 속도 분류 결과에 비해 낮은 성능을 나타내었다. 또한, 학습 데이터와의 조도 차이가 비교적 적은 1,240lx 시험 영상의 속도 분류 결과보다 더 낮은 성능을 나타내었다.

결과적으로 학습용 데이터보다 높은 조도 환경에서 속도 분류작업을 수행할 경우 그림 12에 나타난 바와 같이 학습 및 시험 영상의 조도 차이가 클수록 더 낮은 분류 성능을 나타냄을 확인하였다.

Table 19. Classification performance with 2,780 lx test set by YOLOv4 model trained under the 570 lx

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
570 lx (1,088 images)	2,780 lx (272 images)	Precision	85.22
		Recall	89.06
		F1 Score	87.10
		Accuracy	87.13




Fig 12. Comparison of classification accuracy of YOLOv4 model trained under the 570 lx for the different illuminance test set



1,240 lx 조건 YOLOv4 학습 모델에 대한 2,780lx 시험 영상의 속도 분류 수행 결과는 표 20과 같으며 272장의 영상 중 8장의 영상에 대해 한 단계 높거나 낮은 속도 단계로 오분류한 것으로 나타났다.

Table 20. Classification result with 2,780 lx test set by YOLOv4 model trained under the 1,240 lx

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	32				32
Stage 2		78	2		80
Stage 3		1	74	5	80
Stage 4				80	80
Total	32	80	76	85	272

표 20의 결과를 기반으로 흑토마토 속도 분류 성능을 평가한 결과, 표 21에 나타낸 바와 같이 평균 Precision은 97.56%, Recall은 97.50%, F1 Score는 97.53%, Accuracy는 97.06%로 측정되었으며 동일 조도 조건 시험 영상의 속도 분류 결과에 비해 비교적 낮은 성능을 나타내었다.

Table 21. Classification performance with 2,780 lx test set by YOLOv4 model trained under the 1,240 lx

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
1,240 lx (1,088 images)	2,780 lx (272 images)	Precision	97.56
		Recall	97.50
		F1 Score	97.53
		Accuracy	97.06

1,240lx 조건 YOLOv4 학습 모델에 대한 570lx 시험 영상의 속도 분류 수행 결과는 표 22와 같으며 272장의 영상 중 27장의 영상에 대해 한 단계 높거나 낮은 속도 단계로 오분류한 것으로 나타났다.

Table 22. Classification result with 570 lx test set by YOLOv4 model trained under the 1,240 lx

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	25	7			32
Stage 2		76	4		80
Stage 3		9	65	6	80
Stage 4			1	79	80
Total	25	92	70	85	272

표 22의 결과를 기반으로 흑토마토 속도 분류 성능을 평가한 결과, 표 23에 나타낸 바와 같이 평균 Precision은 92.10%, Recall은 88.28%, F1 Score는 90.15%, Accuracy는 90.07%로 측정되었으며 마찬가지로 동일 조도 조건 시험 영상의 속도 분류 결과에 비해 비교적 낮은 성능을 나타내었다. 또한, 학습 데이터보다 조도가 높은 2,780lx 시험 영상의 속도 분류 결과보다 더 낮은 성능을 나타내었다.

결과적으로 학습용 데이터보다 높거나 낮은 조도 환경에서 속도 분류작업을 수행할 경우 그림 13에 나타낸 바와 같이 학습 영상보다 시험 영상의 조도가 낮은 경우에 더 낮은 분류 성능을 나타냄을 확인하였다.

Table 23. Classification performance with 570 lx test set by YOLOv4 model trained under the 1,240 lx

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
1,240 lx (1,088 images)	570 lx (272 images)	Precision	92.10
		Recall	88.28
		F1 Score	90.15
		Accuracy	90.07

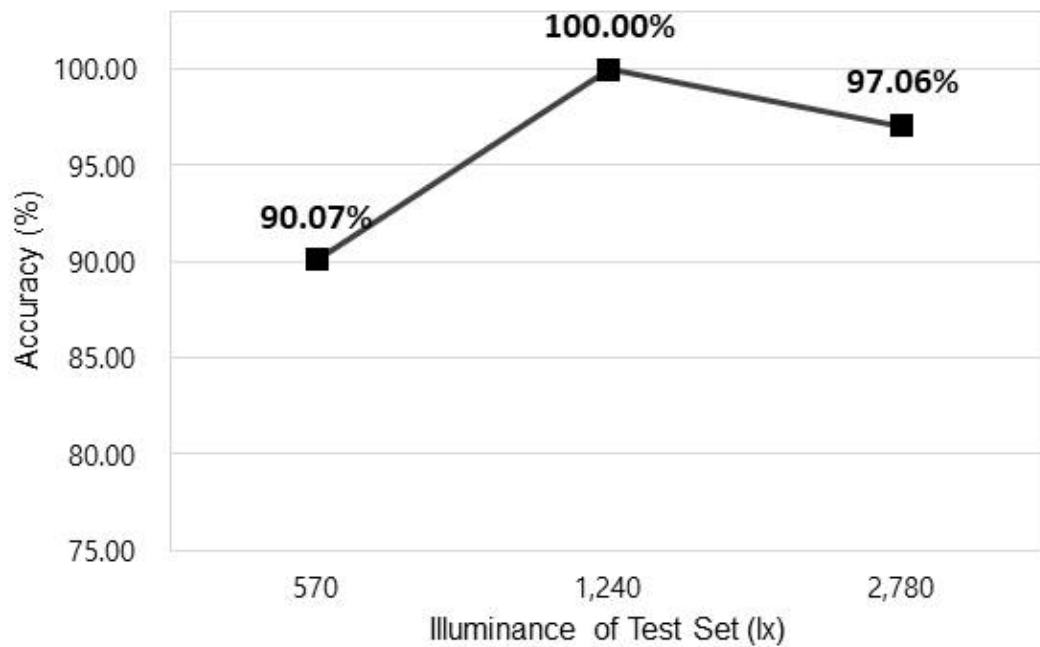


Fig 13. Comparison of classification accuracy of YOLOv4 model trained under the 1,240 lx for the different illuminance test set

2,780 lx 조건 YOLOv4 학습 모델에 대한 1,240 lx 시험 영상의 속도 분류 수행 결과는 표 24와 같으며 272장의 영상 중 2장의 영상에 대해 한 단계 높거나 낮은 속도 단계로 오분류한 것으로 나타났다.

Table 24. Classification result with 1,240 lx test set by YOLOv4 model trained under the 2,780 lx

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	32				32
Stage 2		79	1		80
Stage 3		1	79		80
Stage 4				80	80
Total	32	80	80	80	272

표 24의 결과를 기반으로 흑토마토 속도 분류 성능을 평가한 결과, 표 25에 나타낸 바와 같이 평균 Precision, Recall, F1 Score는 각각 99.38%, Accuracy는 99.26%로 측정되었다. 동일 조도 조건 시험 영상의 속도 분류 결과에 비해 크지는 않으나 분류 성능 조금 낮아진 것으로 나타났다.

Table 25. Classification performance with 1,240 lx test set by YOLOv4 model trained under the 2,780 lx

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
2,780lx (1,088 images)	1,240lx (272 images)	Precision	99.38
		Recall	99.38
		F1 Score	99.38
		Accuracy	99.26

2,780 lx 조건 YOLOv4 학습 모델에 대한 570 lx 시험 영상의 속도 분류 수행 결과는 표 26과 같으며 272장의 영상 중 40장의 영상에 대해 한 단계 높거나 낮은 속도 단계로 오분류한 것으로 나타났다.

Table 26. Classification result with 570 lx test set by YOLOv4 model trained under the 2,780 lx

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	16	16			32
Stage 2		67	13		80
Stage 3		3	77		80
Stage 4			8	72	80
Total	16	86	98	72	272

표 26의 결과를 기반으로 흑토마토 속도 분류 성능을 평가한 결과, 표 27에 나타낸 바와 같이 평균 Precision은 89.12%, Recall은 80.00%, F1 Score는 84.31%, Accuracy는 85.29%로 측정되었으며 마찬가지로 동일 조도 조건 시험 영상의 속도 분류 결과에 비해 낮은 성능을 나타내었다. 또한, 학습 데이터와의 조도 차이가 비교적 적은 1,240lx 시험 영상의 속도 분류 결과보다 더 낮은 성능을 나타내었다.

결과적으로 학습용 데이터보다 낮은 조도 조건에서 속도 분류 작업을 수행할 경우 그림 14에 나타낸 바와 같이 학습 및 시험 영상의 조도 차이가 클수록 더 낮은 분류 성능을 나타냄을 확인하였다.

Table 27. Classification performance with 570 lx test set by YOLOv4 model trained under the 2,780 lx

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
2,780lx (1,088 images)	570lx (272 images)	Precision	89.12
		Recall	80.00
		F1 Score	84.31
		Accuracy	85.29

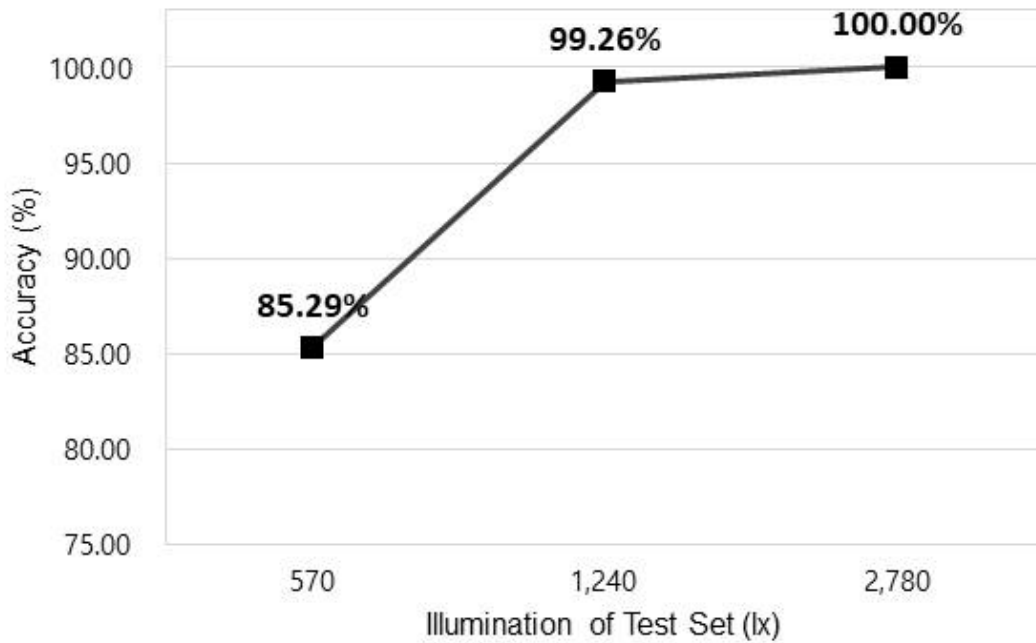



Fig 14. Comparison of classification accuracy of YOLOv4 model trained under the 2,780 lx for the different illuminance test set

학습용 데이터의 조도와 다른 조도의 시험 영상에 대한 속도 분류 수행 결과 그림 15와 같이 동일한 영상에 대해 조도별 YOLOv4 학습 모델에 따라 다른 속도 단계로 분류하는 경우가 발생하였다. 표 28은 두 가지 다른 조도의 시험 영상에 대해 측정한 각 조도별 YOLOv4 학습 모델의 분류 성능을 평균하여 나타낸 것이다. 평균 분류 정확도는 570 lx, 1,240 lx, 2,780 lx 조건 YOLOv4 학습 모델에 대하여 각각 92.83%, 93.57%, 92.28%로 측정되었으며, 그림 16과 같이 모두 동일한 조도의 시험 영상 분류 결과보다 낮은 성능을 나타내었다. 즉, 570 lx ~ 2,780 lx 범위에서 단일 조도 조건의 영상만을 학습한 YOLOv4 모델은 조도가 변화하는 분류 환경에 적응성이 떨어짐을 확인하였다.



(a) Correct classification

(b) Incorrect classification

Figure 15. Example of incorrect classification results for the same black tomato due to a YOLOv4 model trained by different illuminance

Table 28. Average classification performance of YOLOv4 models trained under each 570 lx, 1,240 lx, 2,780 lx for the different illuminance test set

Illuminance of Training Set	Precision (%)	Recall (%)	F1 Score (%)	Accuracy (%)
570 lx	92.00	93.91	92.93	92.83
1,240 lx	94.83	92.89	93.84	93.57
2,780 lx	94.25	89.69	91.85	92.28

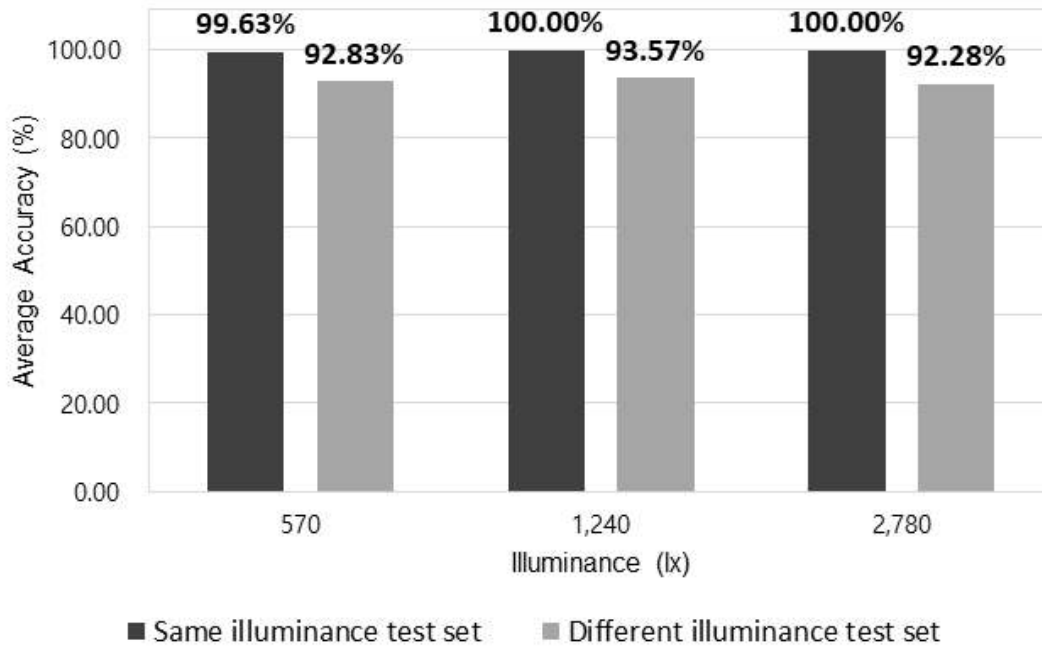


Fig 16. Comparison of average classification accuracy between the same illuminance test set and different illuminance test set as the training set



#### 다. 혼합 조도 조건 YOLOv4 학습 모델의 속도 분류 성능

단일 조도 조건의 흑토마토 영상만을 학습한 YOLOv4 모델은 동일 조도 조건의 영상에 대해서는 높은 분류 성능을 나타내었지만 다른 조도 조건의 영상에 대해서는 비교적 낮은 분류 성능을 나타내었다. 이 경우 조도가 변화할 수 있는 실제 속도 분류 환경에서 높은 분류 성능을 유지하기 위해 동일한 조도를 항상 일정하게 유지하도록 관리하거나 조도 변화에 대하여 매번 모델을 캘리브레이션해야 하는 불편함이 발생할 수 있다. 이에 본 연구에서는 조도의 변화와 상관없이 속도 단계를 분류하기 위하여 570 lx, 1,240 lx, 2,780 lx 세 수준의 조도에서 촬영한 흑토마토 영상을 함께 학습한 혼합 조도 조건 YOLOv4 학습 모델의 속도 분류 성능을 분석하였다.

혼합 조도 조건 YOLOv4 학습 모델은 표 7의 데이터 구성에 따라 세 수준의 조도에서 흑토마토의 상, 하, 좌, 우 4면을 촬영한 영상 3,264장을 사용하여 학습하였으며 학습에 사용하지 않은 시험 영상 816장에 대하여 속도 분류 성능을 평가하였다.

혼합 조도 조건 YOLOv4 학습 모델에 대한 속도 분류 수행 결과는 표 29와 같으며 816장의 시험 영상에 대하여 모두 정확히 분류한 것으로 나타났다.

Table 29. Classification result of YOLOv4 model trained under all illuminance conditions

Predicted Actual	Stage 1	Stage 2	Stage 3	Stage 4	Total
Stage 1	96				96
Stage 2		240			240
Stage 3			240		240
Stage 4				240	240
Total	96	240	240	240	816

표 29의 결과를 기반으로 흑토마토 속도 분류 성능을 평가한 결과, 표 30에 나타낸 바와 같이 평균 Precision, Recall, F1 Score, Accuracy 모두 각각 100.00%로 측정되었다. 즉, 570 lx ~ 2,780 lx 범위에서 여러 조도의 영상을 혼합하여 함께 학습한 YOLOv4 모델은 해당 조도 범위에서 조도의 변화와 상관 없이 여러 방향의 흑토마토에 대해 속도를 높은 성능으로 잘 분류할 수 있음을 확인하였다.

Table 30. Classification performance of YOLOv4 model trained under all illuminance conditions

Illuminance of Training Set	Illuminance of Test Set	Index	Value (%)
570 lx	570 lx	Precision	100.00
1,240 lx	1,240 lx	Recall	100.00
2,780 lx	2,780 lx	F1 Score	100.00
(3,264 images)	(816 images)	Accuracy	100.00

## 2. 학습 데이터셋 크기의 영향

흑토마토 속도 분류를 위한 딥러닝 학습을 위해서 영상 수집 및 데이터 라벨링을 수작업하는데 많은 시간이 소요된다. 이에 영상 수집 및 라벨링 작업의 최소화를 위하여 유의성 있는 분류 성능을 위해 필요한 최소 학습 데이터셋의 크기를 분석하고자 하였다. 이를 위하여 혼합 조도 조건 YOLOv4 학습 모델의 학습용 데이터 3,264장에 대해 조도 조건 및 촬영 방향을 고려해 12.5%, 25.0%, 37.5%, 50.0%, 62.5%, 75.0%, 87.5%, 100.0%의 비율로 흑토마토 영상을 무작위로 선택하여 총 8개의 서로 다른 크기의 학습 데이터셋을 구성하였다. 각 학습 데이터셋 크기별 YOLOv4 모델은 각각 혼합 조도 조건 YOLOv4 학습 모델의 시험용 데이터 816장에 대하여 속도 분류 성능을 평가하였다.

학습 데이터셋 크기에 따른 YOLOv4 학습 모델의 속도 분류 성능은 표 31과 같다. 학습 데이터셋의 크기가 증가함에 따라 분류 성능이 향상되는 것으로 나타났다. 1,632장 이상의 학습 데이터셋에 대하여 95.00% 이상의 분류 정확도를 나타내었다.

Table 31. Classification performance according to training set sizes

Size of Training Set	Precision (%)	Recall (%)	F1 Score (%)	Accuracy (%)
408	92.48	89.48	90.96	89.83
816	93.70	92.14	92.91	92.03
1,224	94.40	92.50	93.44	92.65
1,632	97.43	97.03	97.23	<b>96.69</b>
2,040	99.90	99.74	99.82	<b>99.88</b>
2,448	99.90	99.74	99.82	<b>99.88</b>
2,856	100.00	100.00	100.00	<b>100.00</b>
3,264	100.00	100.00	100.00	<b>100.00</b>




Figure 17. Comparison of classification accuracy according to training set sizes

### 3. 데이터 학습량의 영향

딥러닝 학습 소요시간 최소화를 위하여 유의성 있는 분류 성능을 위해 필요한 최소 학습량도 분석하였다. 이를 위하여 혼합 조도 조건 YOLOv4 학습 모델의 학습 데이터셋 크기 중 95.00% 이상의 분류 성능을 나타낸 최소 학습 데이터셋 크기인 1,632장에 대해 8,000회까지 1,000회 단위로 반복 학습한 결과를 비교하였다. 학습량에 따른 혼합 조도 조건 YOLOv4 학습 모델은 각각 시험 영상 816장에 대하여 속도 분류 성능을 평가하였다.

학습량에 따른 속도 분류 성능은 표 32와 같으며 결과적으로 570 lx, 1,240 lx, 2,780 lx 세 수준의 조도에서 촬영한 1,632장의 흑토마토 영상을 3,000번 이상 반복 학습한 YOLOv4 모델에 대하여 95.00% 이상의 분류 정확도를 나타내었다.

Table 32. Classification performance according to training steps

Training Step	Precision (%)	Recall (%)	F1 Score (%)	Accuracy (%)
1,000	83.93	79.32	81.56	77.70
2,000	94.36	92.71	93.53	92.89
3,000	97.32	96.82	97.07	<b>96.81</b>
4,000	98.04	97.76	97.90	<b>97.55</b>
5,000	97.14	96.51	96.82	<b>96.45</b>
6,000	96.81	95.99	96.40	<b>95.83</b>
7,000	98.06	97.92	97.99	<b>97.55</b>
8,000	97.43	97.03	97.23	<b>96.69</b>




Figure 18. Comparison of classification accuracy according to training steps

## V. 요약 및 결론

본 연구는 수확된 흑토마토의 속도를 실시간으로 자동선별하는 시스템 개발을 위한 기초연구로, 딥러닝 분야에서 빠른 속도와 높은 정확도를 보이는 최신 One-Stage detector인 YOLOv4를 사용하여 속도 분류를 수행하였다. 딥러닝 학습 및 시험에 필요한 흑토마토 영상을 수집하기 위해 영상 수집용 머신 비전 시스템을 구축하였으며 최소 데이터와 학습량으로 시간 효율적이고 실제 속도 분류 환경에서 높은 성능과 적응성을 나타내는 모델을 위해 조도 조건, 학습 데이터셋 크기, 학습량에 따른 YOLOv4 학습 모델의 속도 분류 성능을 평가하였다. 그 주요 결과를 요약하면 다음과 같다.

1. 흑토마토 속도 분류를 위한 디지털 영상을 수집하기 위하여 MILC 카메라, 조명장치, 편광필터 등으로 구성된 영상 수집용 머신 비전 시스템을 구축하였으며 4단계의 속도 단계 설정 기준에 따라 분류한 ‘블랙체인지’ 품종 흑토마토 340개를 570 lx, 1,240 lx, 2,780 lx 세 수준의 조도에서 시료 1개당 상, 하, 좌, 우 4면을 촬영한 총 4,080장의 영상을 활용하였다.
2. 570 lx, 1,240 lx, 2,780 lx 세 수준의 조도에서 촬영한 흑토마토 영상을 학습한 단일 조도 조건 YOLOv4 학습 모델에 대해 동일 조도 조건 시험 영상의 속도 분류를 수행한 결과 각각 99.63%, 100.00%, 100.00%의 높은 분류 정확도를 나타내었으며 570 lx ~ 2,780 lx 범위에서 조도의 세기는 분류 성능에 큰 영향을 주지 않는 것으로 판단되었다.
3. 단일 조도 조건 YOLOv4 학습 모델에 대해 다른 두 조도 조건 시험 영상의 속도 분류를 수행한 결과는 각각 92.83%, 93.57%, 92.28%로 동일 조도 조건 시험 영상에 비해 낮은 평균 분류 정확도를 나타내었다. 즉, 570lx ~ 2,780lx 범위에서 특정 조도의 영상만을 학습한 단일 조도 조건 YOLOv4 모델은 조도가 변화하는 분류 환경에 적응성이 낮다고 판단되었다.

4. 세 수준의 조도에서 촬영한 흑토마토 영상을 함께 학습한 혼합 조도 조건 YOLOv4 학습 모델의 속도 분류 수행 결과 100.00%의 높은 분류 정확도로 여러 조도 조건 및 방향의 흑토마토 영상을 모두 잘 분류한 것으로 나타났다. 즉, 570lx ~ 2,780lx 범위에서 다양한 조도 조건의 영상을 함께 학습한 YOLOv4 학습 모델은 조도 변화에 따른 오분류 현상을 개선하는 방법이 될 수 있으며 단일 조도 조건 YOLOv4 모델보다 조도가 변화하는 분류 환경에 적응성이 높다고 판단되었다.

5. 영상 수집 및 라벨링 작업의 최소화를 위해 학습 데이터셋의 크기에 따른 혼합 조도 조건 YOLOv4 학습 모델의 흑토마토 속도 분류 성능을 분석한 결과 데이터셋의 크기가 증가함에 따라 분류 성능이 향상되었으며 1,632장 이상부터 95.00% 이상의 유의성 있는 분류 성능을 나타내었다.

6. 딥러닝 학습 소요시간 최소화를 위해 1,632장의 학습용 데이터를 이용한 혼합 조도 조건 YOLOv4 모델에 대하여 학습량에 따른 흑토마토 속도 분류 성능을 분석한 결과 3,000번 이상 반복 학습한 이후부터 95.00% 이상의 유의성 있는 분류 성능을 나타내었다.

7. 본 연구에서 제시한 영상 수집 방법, 조도 조건, 학습 데이터셋 크기 및 학습량을 통해 얻은 높은 분류 성능평가 결과는 실시간 흑토마토 속도 자동 선별시스템의 개발 및 개선에 기여할 수 있으리라 기대된다.



## 참 고 문 헌

Arakeri, M. P., and Lakshmana. 2016. Computer Vision Based Fruit Grading System for Quality Evaluation of Tomato in Agriculture industry. *Procedia – Procedia Comput. Sci.*, Vol. 79, pp. 426-433.

Arjenaki O. O., P. A. Moghaddam, and A. M. Motlagh. 2013. Online tomato sorting based on shape, maturity, size, and surface defects using machine vision. *Turkish Journal of Agriculture and Forestry*, Vol. 37, pp. 62-68.

Bejo, S. K., and S. Kamaruddin. 2014. Determination of Chokanan mango sweetness (*Mangifera indica*) using non-destructive image processing technique. *Austr. J. Crop Sci.* 8, 475-480.

Bochkovsky, A., C. Y. Wang, and H. M. Liao. 2020. YOLOv4: Optimal Speed and Accuracy of Object Detection. *arXiv preprint arXiv:2004.10934*.

Borghesi, E., M. L. Gonzalez-Miret, M. L. Escudero-Gilete, F. Malorgio, F. J. Heredia, and A. J. Melendex-Martinex. 2011. Effects of salinity stress on carotenoids, anthocyanins, and color of diverse tomato genotypes. *J Agr Food Chem* 59:11676-11682.

Choi, K. H., K. J. Lee, D. S. Choi, and J. H. Yun. 1999. Development of Automatic Tomato Grading System. *Proceedings of the Korean Society for Agricultural Machinery 1999 Summer Conference* 4(2), 282-289.

Dumas, Y., M. Dadomo, G. Di Lucca, and P. Grolier. 2003. Effects of environmental factors and agricultural techniques on antioxidant content of

tomatoes. *Journal of the Science of Food and Agriculture*, Vol. 83, No. 5, pp. 369–382.

El-Bendary, N., E. E. Hariri, A. E. Hassanien, and A. Badr. 2015. Using machine learning techniques for evaluating tomato ripeness. *Expert Systems with Applications*, Vol. 42, No. 4, pp. 1892–1905.

Gautier, H., V. Diakou-Verdin, C. Benard, M. Reich, M. Buret, F. Bourgaud, J. L. Poessel, C. Caris-Veyrat, and M. Genard. 2008. How Does Tomato Quality (Sugar, Acid, and Nutritional Quality) Vary with Ripening Stage, Temperature, and Irradiance. *Journal of Agricultural and Food Chemistry*, Vol. 56, No. 4, pp. 1241–1250.

Hasan, R., S. Muhammad, and G. Monir. 2017. Fruit maturity estimation based on fuzzy classification. *Proceedings of the 2017 IEEE International Conference on Signal and Image Processing Applications (ICSIPA)*, pp. 27–32, Kuching, Malaysia.

Kim, D. Y., and B. K. Cho. 2009. Study on Quality Measurement of Cherry Tomato using Color Imaging. *Proceedings of the Korean Society for Agricultural Machinery 2009 Winter Conference* 14(1), 382–386.

Kim, D. Y., H. K. Oh, N. K. Lee, Y. S. Kim, and B. K. Cho. 2010. Study on Quality Factor Measurement for Cherry Tomato using Color Imagery. *Journal of Agricultural Science*, Vol. 37, No. 2, pp. 303–308.

Klee, H. J., and J. J. Giovannoni, “Genetics and Control of Tomato Fruit Ripening and Quality Attributes,” *Annual Review of Genetics*, Vol. 45, No. 1, 99.41–59, 2011.

Ko, K. E., S. H. Yang, and I. H. Jang. 2018. Real-Time Tomato Ripeness Classification System based on Deep Learning Model for Object Detection. *Journal of Institute of Control, Robotics and Systems*, 24(11), 999–1004

Radzevičius, A., R. Karklelienė, P. Viškelis, Č. Bobinas, R. Bobinaitė, S. Sakalauskienė, and L. Metspalu. 2009. Tomato (*Lycopersicon esculentum* Mill.) fruit quality and physiological parameters at different ripening stages of Lithuanian cultivars. *Agronomy Research*, Vol. 7, No. Special Issue II, pp. 712–718.

RDA. 2016. Agricultural Food Consumption Trend of 2016 for Farmers in Gangwon Province, pp. 58.

Redmon, J., S. Divvala, R. Girshick, and A. Farhadi. 2016. You only look once: Unified, Real-Time Object Detection. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, 99. 779–788.

Sanaeifar, A., A. Bakhshipour, and M. de la Guardia. 2016. Prediction of banana quality indices from color features using support vector regression. *Talanta* 148, 54–61.

Wan, P., A. Toudeshki, H. Tan, and R. Ehsani. 2018. A methodology for fresh tomato maturity detection using computer vision. *Computers and Electronics in Agriculture*, vol. 146, pp. 43–50.

Zhang, L., J. Jia, G. Gui, X. Hao, W. Gao, and M. Wang. 2018. Deep learning based improved classification system for designing tomato harvesting robot. *IEEE Access*, vol. 6, pp. 67940–67950.

# **Classification of Black Tomato Ripeness based on YOLOv4 Model using Digital Image**

Yang Hyun Cho

Department of Rural and Biosystems Engineering

Graduate School Chonnam National University

(Supervised by Professor Yeong Soo Choi)

(abstract)

There is a rising interest on Black tomato as a functional high-quality tomato because it contains various minerals, vitamins and large amounts of antioxidants compared to other types of tomatoes. Ripeness is an important factor that determines the quality of black tomatoes such as sugar content, color, and nutrients, and it is necessary to classify ripeness accurately for improving the commercial value during distribution after harvest.

In this study, a black tomato ripeness classification model was developed using YOLOv4, the latest object detection deep learning model, as a basic research for the development of a real-time automatic black tomato ripeness grading system. Also, in order to develop a model that is capable of high performance and adaptability in an actual ripeness classification environment with minimal data and training steps, the ripeness classification performance of the trained YOLOv4 model was evaluated according to illuminance conditions, training set size, and training step.

To collect black tomato images for training and testing of deep learning models, we have established a machine vision system consisting of MILC cameras, lighting devices, and polarizing filters. Total number of 340 black tomatoes of the 'Black Change' variety were classified into four ripeness stages. Images were acquired under three kinds of illuminance (570 lx, 1,240 lx, and 2,780 lx.) and four directions of top, bottom, lateral left and right sides. So, 4,080 images of JPEG format with resolution  $4,912 \times 3,264$  were used for the classification.

As a result of analyzing the effect of illuminance conditions, the ripeness classification performance with the test set acquired under the same illuminance was more than 99.00% when the single illumination condition YOLOv4 training model was applied. However, the performance with the test set acquired under the different illuminance was relatively low. Therefore, the result showed that the adaptability of the model trained under specific illuminance condition can be low to the actual classification environment in which the illuminance is different. On the other hand, the mixed illuminance condition YOLOv4 model, which trained with the images acquired at all of three levels of illuminance together, showed a high classification performance of 100.00% regardless of the direction and illuminance change. So, it is recommended that all possible illuminance should be considered into the development of the classification model for improving its adaptability.

As a result of analyzing the effect of the training set size and training step, the classification performance of over 95.00% was obtained when the model was trained over 3,000 iterations with 1,632 images by the mixed illuminance condition YOLOv4 training model.